



# تئوری تخمین و فیلترهای بهینه

فصل سوم:

تخمین بهینه

استاد مدرس:  
دکتر سعید عباداللهی

فصل سوم

# تخمین بهینه

## مقدمه

تخمین بهینه (Optimal Estimation) یکی از بهترین حدس‌های ممکن است.

در این فصل به موارد زیر خواهیم پرداخت:

✓ ارائه مسئله تخمین بهینه

✓ برخی ویژگی‌های مطلوب یک تخمین

✓ معرفی سه معیار رایج بهینگی، عبارت از:

❖ معیار حداقل میانگین مربعات خطا: Minimum Mean-Square Error Criteria

❖ بیشترین احتمال پسین: Minimum Mean-Square Error Criteria

❖ بیشترین احتمال: Maximum Likelihood

فرموله سازی مسئله

تخمین بیشترین احتمال  
و بیشترین احتمال پسین

تخمین حداقل میانگین  
مربعات خطا

- سیگنال  $s(t)$  را در نظر بگیرید.
- فرض:  $s(n)$  را به عنوان سیگنال نمونه برداری شده
- اندازه گیری های به دست آمده از سیگنال  $s(n)$  به صورت زیر در اختیار است:

$$z(n) = g(s(n), v(n), n)$$

که در آن:

➤  $v(n)$ : سیگنال نویز

➤  $g$ : تابع نشان دهنده مخدوش شدن سیگنال  $s(n)$  در تولید  $z(n)$

هدف: محاسبه تخمینی بهینه از  $s(n)$  در لحظه  $n$  براساس مشاهدات  $z(1), z(2), \dots, z(n)$ :

$$\hat{s}(n) = \alpha_n(z(1), z(2), \dots, z(n))$$

➤  $\alpha_n$ : تابعی وابسته به  $n$

➤  $\hat{s}(n)$ : تخمین بهینه

فرموله سازی مسئله

تخمین بیشترین احتمال  
و بیشترین احتمال پسین

تخمین حداقل میانگین  
مربعات خطا

به منظور توجه به عدم قطعیت موجود و ایجاد امکان برای تعریف یک معیار بهینگی مناسب:

- فرض:  $s(n)$  و  $v(n)$  به ترتیب به صورت سیگنال‌های تصادفی  $s(n)$  و  $v(n)$

- اندازه‌گیری  $z(n)$  را نیز به صورت سیگنال تصادفی  $z(n)$  تعریف می‌کنیم:

$$z(n) = g(s(n), v(n), n)$$

- به علاوه  $\hat{s}(n)$  نیز به صورت سیگنال تصادفی  $\hat{s}(n)$  تعریف می‌گردد:

$$\hat{s}(n) = \alpha_n(z(1), z(2), \dots, z(n))$$

## مسئله تخمین بهینه

با در نظر گرفتن:

✓ اندازه‌گیری‌های  $z(1), z(2), \dots, z(n)$

✓ تابع  $g$

✓ و یک معیار بهینگی

تخمین‌گری طراحی کنید که تخمین بهینه  $\hat{s}(n)$  مربوط به  $s(n)$  را با در نظر گرفتن تابعی مانند  $\alpha_n$  ارائه دهد:

$$\hat{s}(n) = \alpha_n(z(1), z(2), \dots, z(n))$$

## پیش‌بینی ، فیلترینگ و هموارسازی

فرموله‌سازی مسئله

تخمین بیشترین احتمال  
و بیشترین احتمال پسین

تخمین حداقل میانگین  
مربعات خطا

**فیلترینگ (Filtering) :** در این حالت سیگنال  $s(n)$  در لحظه  $n$  بر اساس اندازه‌گیری‌های  $z(1), z(2), \dots, z(n)$  تخمین زده می‌شود.

**پیش‌بینی (Prediction) :** در این حالت سیگنال  $s(n)$  در یک نقطه زمانی در آینده و خارج از بازه زمانی مشاهدات  $z(1), z(2), \dots, z(n)$  تخمین زده می‌شود. مثال:  $s(n+1)$  یا  $s(n+20)$

**هموارسازی (Smoothing) :** در این حالت سیگنال  $s(n)$  در یک نقطه زمانی قبل از  $n$  تخمین زده می‌شود و از مشاهدات بعدی تا لحظه  $n$  برای هموار کردن خطای تخمین استفاده می‌شود. (مثال: تخمین  $s(n-1)$  یا  $s(n-16)$ )



## انواع مسئله تخمین

<u>t</u>	<u>تخمین</u>	<u>مسئله تخمین</u>
$n$	$\hat{s}(n)$	فیلترینگ
$n+1$	$\hat{s}(n+1)$	پیش‌بینی یک گام
$n+m, m > 0$	$\hat{s}(n+m)$	پیش‌بینی m گام
$n-1$	$\hat{s}(n-1)$	هموارسازی با یک گام روبه عقب
$n-m, m > 0$	$\hat{s}(n-m)$	هموارسازی با m گام روبه عقب
$m \text{ constant}$	$\hat{s}(m)$	هموارسازی نقطه ثابت



## ویژگی‌های تخمین‌ها

بیان ویژگی‌های یک تخمینگر به منظور ارزیابی تخمینگر:

میانگین  $\hat{s}(n)$  = میانگین واقعی  $s(n)$

$$E[\hat{s}(n)] = E[s(n)]$$

که این ویژگی معادل است با:

$$\tilde{s}(n) = s(n) - \hat{s}(n)$$

خطای تخمین

$$E[\hat{s}(n)] = E[s(n)]$$

اگر این شرط محقق شود، آنگاه:

تخمین بدون بایاس یا Unbiased Estimate

❖  $\alpha$  : تخمینگر بدون بایاس

## ویژگی‌های تخمین‌ها

### 1. Asymptotically Unbiased Estimation : اگر

$$\lim_{n \rightarrow \infty} E[\hat{s}(n)] = E[s(n)]$$

شرط ضعیف‌تر

باشد، آنگاه تخمین انجام شده در طول یک بازه زمانی را به صورت مجانبی بدون بایاس گویند.

### 2. Consistent Estimator (تخمینگر سازگار): و چنانچه

$$\lim_{n \rightarrow \infty} E[\underbrace{\tilde{s}^2(n)}_{\text{میانگین مربعات خطا}}] = 0$$

MSE

باشد، در این صورت تخمینگر تولیدکننده را سازگار گویند.

اگر هر دو شرط ۱ و ۲ در خصوص یک تخمین برقرار باشند، یعنی اگر یک تخمینگر هم (به طور مجانبی) بدون بایاس باشد و هم سازگار، در این صورت:

$$\text{if } n \rightarrow \infty \Rightarrow E[\tilde{s}^2(n)] \rightarrow 0, E[\tilde{s}(n)] \rightarrow 0$$

با همگرایی  $n \rightarrow \infty$  یک تخمین درست از  $s(n)$  بدست می‌آید.



## مثال: فیلتر میانگین

فرض کنید:

فرموله سازی مسئله

تخمین بیشترین احتمال  
و بیشترین احتمال پسین

تخمین حداقل میانگین  
مربعات خطا



حال فیلتر میانگین را در نظر بگیرید:

بدون بایاس بودن و سازگاری تخمینگر را بررسی می کنیم:

## مثال: فیلتر میانگین

داریم:

$$\begin{aligned} E [\hat{s}(n)] &= \frac{1}{n} \sum_{j=1}^n E [z(j)] \\ &= \frac{1}{n} \sum_{j=1}^n (E[s] + E[v(n)]) \\ &= \frac{1}{n} \sum_{j=1}^n (E[s]) \\ &= E[s] \end{aligned}$$

بدون بایاس

## مثال: فیلتر میانگین

و اما سازگاری:

و:

$$E[\hat{s}^2(n)] = \frac{1}{n^2} E[(z(1) + z(2) + \dots + z(n)) (z(1) + z(2) + \dots + z(n))]$$

$$= \frac{1}{n^2} [(nE[s^2] + \sigma_v^2)n]$$

$$\Rightarrow E[\tilde{s}^2(n)] = \underbrace{E[s^2] - 2E[s^2] + E[s^2]}_{\text{if } n \rightarrow \infty: \rightarrow 0} + \frac{\sigma_v^2}{n} = \frac{\sigma_v^2}{n}$$

## تخمین بیشترین احتمال

### Maximum Likelihood Estimation

متغیر تصادفی  $x$  با تابع چگالی احتمال تک مدال  $f_x(x)$  را در نظر بگیرید.

مقداری از  $x$  که منجر به حداکثرسازی تابع  $f_x(x)$  می شود = محتمل ترین مقدار  $x$

فرض کنید که یک اندازه گیری تک از  یعنی یک تحقق نمونه از  در اختیار باشد.

بنابراین طبیعی است، تخمین  $s$  از طریق محاسبه محتمل ترین مقدار برای تولید  محاسبه می شود.

در این راستا تابع چگالی شرطی  به عنوان تابعی از  $s$  در نظر گرفته شده و تابع احتمال نامیده

می شود. بنابراین مقدار  $s$  باید به گونه ای محاسبه شود که تابع احتمال را حداکثر سازد.

این روش تخمین به عنوان تخمین حداکثر احتمال ML شناخته شده و به صورت زیر نشان داده می شود:

$$\hat{s}_{ML} = \text{values of } s \text{ that maximizes } f_z(z | s = s)$$

where  $f_z(z | s = s)$ : likelihood function

## تخمین بیشترین احتمال

فرض کنید تابع احتمال:

- مشتق پذیر
  - دارای یک نقطه ماکزیمم یکتا در دامنه خود
- باشد. بنابراین:

$$\hat{s}_{ML} = \text{value of } s \text{ for which } \frac{\partial f_z(z | s = s)}{\partial s} = 0$$

از آنجایی که تابع لگاریتم طبیعی یک تابع یکنواخت افزایشیست، می توان به صورت معادل به حداکثرسازی تابع احتمال لگاریتمی  $\ln(f_z(z | s = s))$  پرداخت و آنگاه داریم:

$$\hat{s}_{ML} = \text{value of } s \text{ for which } \frac{\partial \ln f_z(z | s = s)}{\partial s} = 0$$

برای هر دو حالت می توان نوشت:

$$\hat{s}_{ML} = \alpha(z)$$



## مثال: تخمین ML

فرض کنید  $s$  و  $z$  متغیرهای تصادفی با تابع چگالی احتمال مشترک زیر باشند:

$$f_{s,z}(s, z) = \begin{cases} \frac{1}{12}(s+z)e^{-z}, & 0 \leq s \leq 4, 0 \leq z < \infty \\ 0 & \text{سایر موارد} \end{cases}$$

هدف: یافتن تخمین ML برای  $s$  بر اساس  $z$

$$\left. \begin{aligned} f_z(z | s = s) &= \frac{f_{s,z}(s, z)}{f_s(s)} \\ f_s(s) &= \int_{-\infty}^{\infty} f_{s,z}(s, z) dz = \int_0^{\infty} \frac{1}{12}(s+z)e^{-z} dz \\ &= \frac{1}{12}[-se^{-z} + (-z-1)e^{-z}]_{z=0}^{\infty} = \frac{1}{12}(s+1), \quad 0 \leq s \leq 4 \end{aligned} \right\} \Rightarrow$$

## مثال: تخمین ML

$$\Rightarrow \underbrace{f_z(z | s=s) = \frac{s+z}{s+1} e^{-z}}_{\text{تابع احتمال}}, \quad 0 \leq s \leq 4, \quad 0 \leq z \leq \infty$$

بنابراین:

$$\frac{\partial f_z(z | s=s)}{\partial s} = \frac{\partial}{\partial s} \frac{s+z}{s+1} e^{-z} = \frac{1-z}{(s+1)^2} e^{-z}$$

$$\begin{cases} z > 1, \frac{\partial f_z(z | s=s)}{\partial s} < 0 \Rightarrow \{s = 0 \rightarrow \max \partial f_z(z | s=s)\} \\ 0 \leq z < 1, \frac{\partial f_z(z | s=s)}{\partial s} > 0 \Rightarrow \{s = 4 \rightarrow \max \partial f_z(z | s=s)\} \\ z = 1, \frac{\partial f_z(z | s=s)}{\partial s} = 0 \Rightarrow \left\{ s = \text{arbitrarily value} = \frac{22}{9} \right\} \end{cases}$$



$$\hat{s}_{ML} = \begin{cases} 4, & 0 \leq z < 1 \\ 22/9, & z = 1 \\ 0, & z > 1 \end{cases}$$

## مثال: تخمین ML در حضور نویز گوسی

فرض کنید:

$$\begin{cases} z = s + v; s, v \text{ are independent} \\ v \sim N(0, \sigma^2) \\ f_v(v) = \frac{1}{2\pi\sigma} e^{-v^2/2\sigma^2} \end{cases}$$

فصل قبل نشان داده شد که:

$$f_z(z | s = s) = f_z(v) |_{v=z-s} = \frac{1}{2\pi\sigma} e^{-(z-s)^2/2\sigma^2}$$

$$\Rightarrow \hat{s}_{ML} = z = \alpha(z)$$

## مثال: تخمین ML بر اساس چندین داده اندازه گیری

فرض کنید:

$$\begin{cases} \forall n : s(n) = s \\ z(n) = s + v(n), s, v \text{ are independent} \\ v(n) \sim N(0, \sigma^2) \end{cases}$$

و بردارهای  $n$  تایی اندازه گیری ها و نویز را نیز داریم:

$$Z_n = \begin{bmatrix} z(1) \\ z(2) \\ \dots \\ z(n) \end{bmatrix}, \quad V_n = \begin{bmatrix} v(1) \\ v(2) \\ \dots \\ v(n) \end{bmatrix}$$

## مثال: تخمین ML بر اساس چندین داده اندازه گیری

تخمین ML یعنی  $\hat{s}_{ML}$  برابرست با:

$\hat{s}_{ML}$  = values of  $s$  that maximizes  $f_{Z_n}(Z_n | s = s)$

تابع چگالی احتمال بردار نویز گوسی  $V_n$  برابرست با:

$$\left\{ \begin{array}{l} f_{V_n}(V_n) = \frac{1}{(2\pi)^{n/2} |P_n|^{1/2}} \exp \left[ \frac{-1}{2} V_n^T P_n^{-1} V_n \right], \\ P_n = \text{Cov} [V_n] \\ |P_n| : \text{determinant of } P_n \end{array} \right.$$

بردار اندازه گیری ها را می توان به صورت زیر نوشت:

$$\left\{ \begin{array}{l} Z_n = \beta s + V_n \\ \beta = [1 \quad 1 \quad \dots \quad 1]^T, \dim(\beta) = n \end{array} \right.$$

## مثال: تخمین ML بر اساس چندین داده اندازه گیری

حال تابع احتمال برابرست با:

$$f_{Z_n}(Z_n | s = s) = f_{V_n}(V_n) |_{V_n = Z_n - \beta s}$$

$$= \frac{1}{(2\pi)^{n/2} |P_n|^{1/2}} \exp \left[ \frac{-1}{2} (Z_n - \beta s)^T P_n^{-1} (Z_n - \beta s) \right]$$

و آنگاه:

$$\begin{cases} \hat{s}_{ML} = \text{values of } s \text{ that maximizes } f_{Z_n}(Z_n | s = s) \\ \text{or} \\ \hat{s}_{ML} = \text{values of } s \text{ that minimizes } (Z_n - \beta s)^T P_n^{-1} (Z_n - \beta s) \end{cases}$$



$$\hat{s}_{ML} = [\beta^T P_n^{-1} \beta]^{-1} \beta^T P_n^{-1} Z_n$$

## مثال: تخمین ML بر اساس چندین داده اندازه گیری

و اگر:

if  $P_n$  is diagonal with  $P_n = \sigma^2 I \Rightarrow \beta^T P_n^{-1} \beta = n/\sigma^2$



$$\beta^T P_n^{-1} = \frac{1}{\sigma^2} [1 \quad 1 \quad \dots \quad 1]$$

و تخمین ML برای مشاهدات  $\{z(n), \dots, z(2), z(1)\}$  برابرست با:

$$\hat{s}_{ML} = \frac{1}{n} \sum_{j=1}^n z(j) = \alpha(z(1), z(2), \dots, z(n))$$



تخمین ML = میانگین مشاهدات

تخمین ML را اغلب رویکرد غیربیزین (non-Bayesian) گویند.



# حداکثرسازی تخمین پسین

## Maximum a Posteriori (MAP) Estimate

در نظر بگیرید که:

$$z = g(s, v)$$

با فرض مشاهده  $z$  محتمل ترین مقدار  $s$  برای وقوع، برابر با مقدار یست که:

$$\hat{s}_{MAP} = \text{values of } s \text{ that maximizes } f_s(s | z = z)$$

این تابع احتمال به عنوان تابع چگالی احتمال پسین شناخته می شود زیرا پس از در اختیار داشتن اندازه گیری  $z$  تعیین می شود.

$$\hat{s}_{MAP} :$$



تخمین حداکثر احتمال پسین MAP نامیده می شود.

فرض کنید:

$$f_s(s | z = z) : \begin{cases} \text{is differentiable} \\ \text{and} \\ \text{has unique maximum in interior of this domain} \end{cases}$$

## حداکثرسازی تخمین پسین

آنگاه:

$$\hat{s}_{MAP} = \text{values of } s \text{ which } \frac{\partial f_s(s | z = z)}{\partial s} = 0$$

با استفاده از فرمول بیز داریم:

$$f_y(y | x = x) = \frac{f_{x,y}(x, y)}{f_x(x)} \Rightarrow f_s(s | z = z) = \frac{f_s(z | s = s) f_s(s)}{f_z(z)}$$

از آنجایی که اندازه گیری  $z$  را داریم و:

$$f_z(z) : \begin{cases} \text{is const} \\ \text{independent of } s \end{cases}$$

$$\hat{s}_{MAP} = \text{values of } s \text{ that maximizes } f_z(z | s = s) f_s(s)$$

تخمین MAP شکلی از تخمین بیزین

## مثال: تخمین MAP در حضور نویز گوسی

داریم:

$$\begin{cases} z = s + v \\ s \sim N(\eta_s, \sigma_s^2) \\ v \sim N(0, \sigma_v^2) \end{cases}$$

در این صورت:

$$f_s(s) = \frac{1}{\sqrt{2\pi}\sigma_s} e^{-(s-\eta_s)^2/2\sigma_s^2}$$

$$f_z(z | s = s) = \frac{1}{\sqrt{2\pi}\sigma_v} e^{-(z-s)^2/2\sigma_v^2}$$

از مثال تابع چگالی شرطی درس دو داریم:

$$\Rightarrow f_z(z | s = s) f_s(s) = \frac{1}{2\pi\sigma_s\sigma_v} \exp\left[-\frac{(z-s)^2}{2\sigma_v^2} - \frac{(s-\eta_s)^2}{2\sigma_s^2}\right]$$

## مثال: تخمین MAP در حضور نویز گوسی

تخمین MAP عبارت فوق را حداکثر می‌سازد که معادل با حداقل سازی عبارت

$$\left[ (z - s)^2 / 2\sigma_v^2 + (s - \eta_s)^2 / 2\sigma_s^2 \right]$$

است. بنابراین:

$$\Rightarrow \frac{\partial f_z(\mathbf{s} | \mathbf{s} = s) f_s(s)}{\partial s} = 0 \Rightarrow \frac{1}{2\sigma_v^2} [2(z - s)(-1)] + \frac{1}{2\sigma_s^2} [2(s - \eta_s)(1)] = 0$$

$$\Rightarrow \hat{s}_{MAP} = \frac{\sigma_v^2}{\sigma_v^2 + \sigma_s^2} \eta_s + \frac{\sigma_s^2}{\sigma_v^2 + \sigma_s^2} z$$

$$\Rightarrow \hat{s}_{MAP} = \eta_s + \frac{\sigma_s^2}{\sigma_v^2 + \sigma_s^2} (z - \eta_s)$$

$$\text{if } \sigma_v^2 \ll \sigma_s^2 \Rightarrow \hat{s}_{MAP} = \eta_s + \frac{\sigma_s^2}{\sigma_s^2} (z - \eta_s) = z = \hat{s}_{ML}$$

# MSE

در نظر بگیرید که:

$$z = g(s, v)$$

با فرض مشاهده  $z$ ، خطای تخمین را به صورت زیر نشان می‌دهیم:

$$\tilde{s} = s - \hat{s}$$

خطای تخمین

در این صورت MSE (میانگین مربعات خطا) برابر است با:

$$MSE = E \left[ E \left[ \tilde{s}^2 \mid z \right] \right] = E \left[ E \left[ (s - \hat{s})^2 \mid z \right] \right] = E \left[ (s - \hat{s})^2 \right]$$

معیار MSE، توان متوسط خطا را ارائه می‌دهد. تخمین MMSE عبارت است از تخمین سیگنال  $s$  با استفاده از مینیمم نمودن میانگین مربعات خطای تخمین یعنی همان  $\hat{s}_{MMSE}$ .

## تخمین MMSE

**قضیه.** با در نظر داشتن متغیر تصادفی  $z$ ، تخمین MMSE (یعنی  $\hat{s}_{MMSE}$ ) برای سیگنال  $s$  برابر است با:

$$\hat{s}_{MMSE} = E[s | z]$$

نتایج قضیه و ویژگی‌های تخمین MMSE:

- تخمین MMSE ( $\hat{s}_{MMSE}$ ) یکتاست.
- تخمین MMSE نیز مشابه رویکرد MAP به اطلاعاتی در مورد  $s$  نیاز دارد.
- ← بنابراین تخمین MMSE نوع دیگری از تخمین بیزین است.
- $z$  یک متغیر تصادفی است:
- ← تخمین  $\hat{s}_{MMSE}$  نیز به نوبه خود یک متغیر تصادفی خواهد بود.

## تخمین MMSE

- تخمین MMSE ( $\hat{s}_{MMSE}$ ) بدون بایاس است. فرض کنید برای متغیر تصادفی  $z$  تحقیقی به صورت  $z$  داریم:

$$\left\{ \begin{array}{l} \hat{s}_{MMSE} = \alpha(z) = E[s | z = z] = \int_{-\infty}^{\infty} s f_s(s | z = z) ds \\ \alpha(z) = \int_{-\infty}^{\infty} s f_s(s | z = z) ds \end{array} \right.$$

$$\begin{aligned} \Rightarrow E[\tilde{s}] &= E[s - \hat{s}_{MMSE}] = E[s - E[s | z]] \\ &= E[s] - E[E[s | z]] = E[s] - E[s] \\ &= 0 \end{aligned}$$

تخمین MMSE بدون بایاس است.



## مثال: تخمین MMSE در حضور نویز گوسی

اندازه‌گیری در حضور نویز جمع‌شونده را با مشخصات زیر در نظر بگیرید:

$$\begin{cases} z = s + v \\ v \sim N(0, \sigma_v^2) \\ \text{we require knowledge } s, \text{ assume } s \sim N(\bar{s}, \sigma_s^2) \\ s, v : \text{are uncorrelated} \end{cases}$$

خواهیم داشت:

$$\Rightarrow \begin{cases} E[s] = E[z] = \bar{s} \\ Var[z] = Var[s] + Var[v] = \sigma_s^2 + \sigma_v^2 \end{cases}$$

همچنین:

$$\left. \begin{aligned} z &= s + v \\ v &\sim N(0, \sigma_v^2) \\ s &\sim N(\bar{s}, \sigma_s^2) \end{aligned} \right\} \Rightarrow z \sim N(\bar{s}, \sigma_s^2 + \sigma_v^2)$$

## مثال: تخمین MMSE در حضور نویز گوسی

بنابراین برای تابع PDF داریم:

$$f_z(z) = \frac{1}{\sqrt{2\pi} \sqrt{\sigma_s^2 + \sigma_v^2}} \exp \left[ -\frac{(z - \bar{s})^2}{2(\sigma_s^2 + \sigma_v^2)} \right]$$

خواهیم داشت:

منتج شده از نتایج پیشین

$$\begin{cases} f_s(s | z = z) = \frac{f_z(z | s = s)}{f_z(z)} \\ f_z(z | s = s) = f_z(v) |_{v=z-s} = \frac{1}{\sqrt{2\pi}\sigma_v} e^{-(z-s)^2/2\sigma_v^2} \end{cases}$$

$\Rightarrow$

$$f_s(s | z = z) = \frac{1}{\sqrt{2\pi}\sigma_s\sigma_v f_z(z)} \exp \left\{ -\left[ \frac{(z-s)^2}{2\sigma_v^2} + \frac{(s-\bar{s})^2}{2\sigma_s^2} \right] \right\}$$

## مثال: تخمین MMSE در حضور نویز گوسی

با جایگذاری  $f_z(z)$  داریم:

$$\Rightarrow f_s(s | z = z) = \frac{1}{\sqrt{2\pi} \sqrt{\frac{\sigma_s^2 \sigma_v^2}{\sigma_s^2 + \sigma_v^2}}} \exp \left\{ - \left[ - \frac{(z - \bar{s})^2}{2(\sigma_s^2 + \sigma_v^2)} + \frac{(z - s)^2}{2\sigma_v^2} + \frac{(s - \bar{s})^2}{2\sigma_s^2} \right] \right\}$$

نتیجه می شود:

$$- \frac{(z - \bar{s})^2}{2(\sigma_s^2 + \sigma_v^2)} - \frac{(z - s)^2}{2\sigma_v^2} + \frac{(s - \bar{s})^2}{2\sigma_s^2} = \frac{(s - \hat{s}_{MAP})^2}{2 \frac{\sigma_s^2 \sigma_v^2}{\sigma_s^2 + \sigma_v^2}}$$

## مثال: تخمین MMSE در حضور نویز گوسی

فرموله‌سازی مسئله

تخمین بیشترین احتمال  
و بیشترین احتمال پسین

تخمین حداقل میانگین  
مربعات خطا



$$f_s(s | z = z) = \frac{1}{\sqrt{2\pi} \sqrt{\frac{\sigma_s^2 \sigma_v^2}{\sigma_s^2 + \sigma_v^2}}} \exp \left[ -\frac{(s - \hat{s}_{MAP})^2}{2 \frac{\sigma_s^2 \sigma_v^2}{\sigma_s^2 + \sigma_v^2}} \right]$$

$$\hat{s}_{MMSE} = E(s | z = z)$$



$$\hat{s}_{MMSE} = E(s | z = z) = \hat{s}_{MAP} = \bar{s} + \frac{\sigma_s^2}{\sigma_s^2 + \sigma_v^2} (z - \bar{s})$$

## اصل تعامد

قضیه اصل تعامد. خطای  $s - E(s|z)$  بر هر تابع  $\gamma(z)$  متعامد است. به عبارت دیگر:

$$E[(s - E[s|z])\gamma(z)] = 0$$

اثبات.

$$\begin{aligned} E[(s - E[s|z])\gamma(z)] &= E[E[(s - E[s|z])\gamma(z)|z]] \\ &= E[E[(s - E[s|z])|z]\gamma(z)] \\ &= E[(E[s|z] - E[E[s|z]|z])\gamma(z)] \\ &= E[(E[s|z] - E[s|z])\gamma(z)] \\ &= 0 \end{aligned}$$

## اصل تعامد

**قضیه.** با در نظر داشتن  $z$ ، تخمین  $\hat{s} = \alpha(z)$ ، تخمین MMSE سیگنال  $s$  است اگر و فقط اگر خطای تخمین یعنی  $s - \alpha(z)$  بر هر تابع  $\gamma(z)$  متعامد باشد. به عبارت دیگر:

$$E[(s - \alpha(z))\gamma(z)] = 0$$

## تخمین MMSE در حالت کلی

**قضیه:** فرض کنید  $Z$  مجموعه‌ای (احتمالاً نامتناهی) از مشاهدات به صورت

$$Z = \{z(n) : n_1 \leq n \leq n_2\}$$

باشد. همچنین با در نظر گرفتن مجموعه اندازه‌گیرهای  $Z$ ، امید شرطی  $s(n)$  به شکل  $E[s(n) | Z]$  نشان داده می‌شود. آنگاه تخمین MMSE سیگنال برابرست با:

$$\hat{s}(n) = E[s(n) | Z]$$



## تخمین MMSE خطی

در عمل اغلب محاسبه تابع چگالی شرطی به سختی انجام می‌شود. علت موضوع آن است که یافتن رابطه  $f_s(s | z = z)$  دشوار است.

یک دسته قدرتمند از توابع، توابع خطی هستند. در اینجا  $\hat{s} = \alpha(z)$  به گونه‌ای محدود می‌شود که تخمین به صورت خطی باشد.

بنابراین به دنبال محاسبه تخمین بهینه خطی LMMSE خواهیم بود. حال تخمین برای ثابتی مانند  $\lambda$  به صورت زیر خواهد بود:

$$\hat{s} = \lambda z$$

در تخمین LMMSE، هدف تعیین  $\lambda$  خواهد بود. در راستای محاسبه  $\lambda$  می‌توان از حداقل‌سازی مستقیم MSE استفاده نمود:

$$MSE = E[(s - \lambda z)^2] = E[s^2 - 2\lambda sz + \lambda^2 z^2]$$

$$\frac{\partial MSE}{\partial \lambda} = 0 \Rightarrow -2E[sz] + 2\lambda E[z^2] = 0$$

بنابراین خواهیم داشت:

$$\lambda = \frac{E[sz]}{E[z^2]}$$

لذا تخمین LMMSE به صورت زیر خواهد بود:

$$\hat{s}_{LMMSE} = \alpha(z) = \left( \frac{E[sz]}{E[z^2]} \right) z$$

در محاسبه تخمین LMMSE نیازی به اطلاعات مربوط به چگالی یا تابع احتمال وجود ندارد. فقط دانستن گشتاورهای مرتبه دوم  $E[sz]$  و  $E[z^2]$  لازم است. حال با استفاده از داده‌های آزمایشگاهی داریم:

$$E[sz] \approx \frac{1}{M} \sum_{m=1}^M (s_m z_m), \quad E[z^2] \approx \frac{1}{M} \sum_{m=1}^M z_m^2$$

قضیه (اصل تعامد در تخمین LMMSE): فرض کنید با در نظر داشتن  $z$  تخمین LMMSE مربوط به  $s$  برابر با  $\alpha(z)$  باشد. در این صورت خطای  $s - \alpha(z)$  بر هر تابع خطی  $\gamma(z)$  متعامد است. به عبارت دیگر خواهیم داشت:

$$E[(s - \alpha(z))\gamma(z)] = 0$$

اثبات:

$$\begin{aligned} E[(s - \alpha(z))\gamma(z)] &= E\left[\left(s - \left(\frac{E[sz]}{E[z^2]}\right)z\right)\beta z\right] \\ &= \beta E[sz] - E\left[\beta \left(\frac{E[sz]}{E[z^2]}\right)z^2\right] \\ &= \beta E[sz] - \beta \frac{E[sz]}{E[z^2]} E[z^2] \\ &= \beta E[sz] - \beta E[sz] \\ &= 0 \end{aligned}$$

## اصل تعامد برای متغیرهای تصادفی برداری

فرض کنید  $s$  و  $z$  بردارهای تصادفی به طور مشترک توزیع شده و به ترتیب دارای ابعاد  $m$  و  $q$  باشند.

محاسبه تخمین LMMSE مربوط به  $s$  به صورت  $\hat{s} = Mz$  به روش زیر عمل خواهیم کرد:

*Let*  $P = E[(s - \hat{s})(s - \hat{s})^T]$

$$\Rightarrow MSE = tr(P) = E[(s - \hat{s})^T (s - \hat{s})]$$

ماتریس  $P$  را می توان به صورت زیر بسط داد:

$$\begin{aligned} P &= E[(s - \hat{s})^T (s - \hat{s})] \\ &= E[ss^T] - ME[zs^T] - E[sz^T]M^T + ME[zz^T]M^T \end{aligned}$$

$$\Rightarrow \boxed{tr(P) = tr(E[ss^T]) - tr(ME[zs^T]) - tr(E[sz^T]M^T) + tr(ME[zz^T]M^T)}$$

## اصل تعامد برای متغیرهای تصادفی برداری

از طرفی:

$$\Rightarrow \frac{\partial}{\partial A} [tr(ABA^T)] = 2AB$$

اگر ماتریس  $AB$  مربعی باشد، آنگاه:

$$\frac{\partial}{\partial A} [tr(AB)] = \frac{\partial}{\partial A} [tr(B^T A^T)] = B^T$$

$$\frac{\partial (tr(P) = tr(E[ss^T]) - tr(ME[zs^T]) - tr(E[sz^T]M^T) + tr(ME[zz^T]M^T))}{\partial M}$$

$\Rightarrow$

$$\frac{\partial}{\partial M} [tr(P)] = -2E[sz^T] + 2ME[zz^T]$$

## اصل تعامد برای متغیرهای تصادفی برداری

if  $\frac{\partial}{\partial M} [tr(P)] = -2E[sz^T] + 2ME[zz^T] = 0 \Rightarrow$

$$M = E[sz^T] (E[zz^T])^{-1}$$

تخمین LMMSE یعنی  $\hat{s}$  برابر می شود با:

$$\Rightarrow \hat{s} = E[sz^T] (E[zz^T])^{-1} z$$

## قضیه: اصل تعامد برای متغیرهای تصادفی برداری

فرض کنید  $s$  و  $z$  بردارهای تصادفی به طور مشترک توزیع شده باشند که در آن  $s$  یک بردار با  $m$  بُعد و  $z$  برداری با بُعد  $q$  است. تخمین LMMSE مربوط به  $s$  را به صورت زیر در نظر بگیرید:

$$\hat{s} = \alpha(z)$$

در این صورت:

$$\underbrace{(s - \hat{s})}_{\text{خطای تخمین}} \perp z$$

به عبارت دیگر:

$$E \left[ (s - \hat{s}) z^T \right] = \mathbf{0}_{m \times q}$$



## قضیه

با در نظر داشتن  $z$ ،  $\alpha(z)$  را تخمین خطی برای  $s$  در نظر بگیرید. در این صورت  $\alpha$ ، معیار  $MSE$  را حداقل می‌سازد اگر و فقط اگر:

$$\underbrace{(s - \alpha(z))}_{\text{خطای تخمین}} \perp z$$

یعنی:

$$E \left[ (s - \alpha(z)) z^T \right] = \mathbf{0}_{m \times q}$$

اگر تخمین خطی  $\alpha(z)$  چنان یافت شود که این رابطه صادق باشد، در این صورت  $\hat{s} = \alpha(z)$  تخمین  $LMMSE$  خواهد بود. اگر  $\alpha$  به حالت خطی محدود باشد، طبق قضیه فقط لازم است  $\alpha$  به گونه‌ای طراحی شود که خطای تخمین بر  $z$  متعامد باشد.



برای محاسبه مقدار  $\lambda$  در رابطه  $\hat{s} = \lambda z$ ، با استفاده از قضیه آخر، می دانیم که مقدار  $\lambda$  مربوط به تخمین  $MMSE$  باید در رابطه زیر صدق کند:

$$E[(s - \alpha(z))z^T] = 0 \Rightarrow E[(s - \lambda z)\beta z] = 0$$

بنابراین خواهیم داشت:

$$\beta E[sz] = \beta \lambda E[z^2] \Rightarrow \underbrace{\lambda = E[sz]/E[z^2]}$$

مشابه رابطه  $\lambda = \frac{E[sz]}{E[z^2]}$  که قبلاً به دست آورده بودیم.

فرض کنید  $s$  و  $z$  هر دو دارای میانگین صفر باشند. آنگاه داریم:

$$\lambda = \frac{E[sz] - E[s]E[z]}{E[z^2] - (E[z])^2} = \frac{\text{Cov}[s, z]}{\sigma_z^2}$$

ضریب همبستگی

$$\rho_{s,z} = \text{Cov}[s, z] / \sqrt{\sigma_s^2 \sigma_z^2}$$

تخمین LMMSE

$$\lambda = \frac{\sigma_s}{\sigma_z} \rho_{s,z} \Rightarrow$$

$$\hat{s}_{\text{LMMSE}} = \rho_{s,z} \frac{\sigma_s}{\sigma_z} z$$

$$\rho_{s,z} = 0$$

فرض کنید  $s$  و  $z$  ناهمبسته باشند، به طوریکه:

در این شرایط، تخمین  $LMMSE$  دقیقاً برابر با صفر خواهد بود که همان میانگین  $s$  است. به عبارت دیگر هر چه همبستگی میان  $s$  و  $z$  بیشتر باشد، در این صورت  $|\rho_{s,z}|$  با حداکثر دامنه یک نیز بزرگتر می شود.

متوسط خطای تخمین



$$E[s - \hat{s}_{MMSE}] = E[s - \lambda z] = 0$$

پس تخمینگر بدون بایاس است.

میانگین مربعات خطا (MSE) نیز برابر می شود با:

$$MSE = E \left[ (s - \hat{s}_{\text{MMSE}})^2 \right] \Rightarrow \hat{s}_{\text{LMMSE}} = \rho_{s,z} \frac{\sigma_s}{\sigma_z} z$$

$$\begin{aligned} MSE &= E[s^2] + \frac{\sigma_s^2}{\sigma_z^2} \rho_{s,z}^2 E[z^2] - 2 \frac{\sigma_s}{\sigma_z} \rho_{s,z} E[sz] \\ &= \sigma_s^2 + \sigma_s^2 \rho_{s,z}^2 - 2 \frac{\sigma_s}{\sigma_z} \rho_{s,z} \text{Cov}[s, z] \\ &= \sigma_s^2 + \sigma_s^2 \rho_{s,z}^2 - 2 \frac{\sigma_s}{\sigma_z} \rho_{s,z} (\rho_{s,z} \sigma_s \sigma_z) \\ &= \sigma_s^2 (1 - \rho_{s,z}^2) \end{aligned}$$

## بهینگی کلی (جامع) Overall Optimality

تخمین MMSE بهینه در مقایسه با سایر تخمینگرها به صورت یک امید ریاضی شرطی است. اما به علت دشواری و یا غیرممکن بودن محاسبه این امید ریاضی شرطی، اغلب تخمین خطی LMMSE محاسبه و اجرا می شود.

تخمین خطی LMMSE نسبت به تخمین MMSE (در مقایسه با همه تخمینگرهای ممکن)، زیر بهینه است. اما اگر  $s$  و  $z$  به طور مشترک گوسی باشند، تخمین LMMSE نیز با تخمین MMSE بهینه برابر می شود.

## مثال: یک تخمین MMSE کلی

فرض کنید  $s$  و  $z$  دارای یک توزیع گوسی دو متغیره با ماتریس کوواریانس  $P$  باشند:

$$P = \begin{bmatrix} \sigma_s^2 & Cov[z, s] \\ Cov[z, s] & \sigma_z^2 \end{bmatrix}$$

حال تخمین  $MMSE$  مربوط به  $s$  برابر است با:

$$\hat{s}_{MMSE} = E[s | z]$$

بنابراین داریم:

$\rho = \rho_{s,z}$

$$\Rightarrow f_{s,z}(s, z) = \frac{1}{2\pi\sigma_s\sigma_z\sqrt{(1-\rho)^2}} \exp \left\{ -\frac{1}{2(1-\rho)^2} \left[ \left( \frac{s}{\sigma_s} \right)^2 - \frac{2\rho sz}{\sigma_s\sigma_z} + \left( \frac{z}{\sigma_z} \right)^2 \right] \right\}$$

## مثال: یک تخمین MMSE کلی

حال با در نظر گرفتن  $z = z$  تابع PDF شرطی مربوط به  $s$  برابر می شود با:

$$f_{s,z}(s | z = z) = \frac{1}{\sqrt{2\pi}\sigma_s\sqrt{(1-\rho)^2}} \exp \left\{ -\frac{1}{2\sigma_s^2(1-\rho)^2} \left( s - \frac{E[sz]}{E[z^2]} z \right)^2 \right\}$$

این رابطه یک تابع PDF به صورت زیر است:

$$N \left( \left( \frac{E[sz]}{E[z^2]} \right) z, \sigma_s^2 (1-\rho)^2 \right)$$

بنابراین داریم:

$$\hat{s}_{MMSE} = E[s | z = z] = \frac{E[sz]}{E[z^2]} z$$

$$\hat{s}_{LMMSE} = \alpha(z) = \left( \frac{E[sz]}{E[z^2]} \right) z \Rightarrow$$

$$\hat{s}_{LMMSE} = \frac{E[sz]}{E[z^2]} z$$

لذا برای متغیرهای تصادفی به طور مشترک گوسی با میانگین صفر، تخمین خطی MMSE بهترین تخمین MMSE کلی نیز خواهد بود.

تخمین حداقل میانگین  
مربعات خطا

تخمین MMSE خطی

مقایسه روش های تخمین

در تخمین ML به جستجوی مقداری از  $s$  پرداخته می شود که تابع احتمال  $f_z(z | s = s)$  را بیشینه سازد. در حقیقت تابع احتمال  $f_z(z | s = s)$  یک تابع چگالی پیشین است و به جای  $z$  تابعی از  $s$  می باشد.

در تخمین MAP به جستجوی مقداری از  $s$  پرداخته می شود که تابع احتمال پسین  $f_z(s | z = z)$  را بیشینه سازد.

- تخمین ML یک روش تخمین غیربیزین
- تخمین MAP یک روش تخمین بیزین



## مثال: تخمین ML و MMSE

فرض کنید  $s$  و  $z$  متغیرهای تصادفی با تابع چگالی احتمال مشترک زیر باشند:

$$f_{s,z}(s, z) = \begin{cases} \frac{1}{12}(s+z)e^{-z}, & 0 \leq s \leq 4, 0 \leq z < \infty \\ 0, & \text{others} \end{cases}$$

خواهیم داشت:

$$f_s(s | z = z) = \left(\frac{1}{4}\right) \frac{s+z}{z+2}, \quad 0 \leq s \leq 4, \quad 0 \leq z < \infty$$

در این صورت تخمین MMSE برابر می شود با:

$$\begin{aligned} \hat{s}_{MMSE} &= E(s | z = z) = \int_0^4 s f_s(s | z = z) ds = \int_0^4 s \left(\frac{1}{4}\right) \left(\frac{s+z}{z+2}\right) ds \\ &= \frac{1}{4(z+2)} \left[ \frac{1}{3} s^3 + \frac{1}{2} s^2 z \right]_{s=0}^4 = \frac{6z+16}{3z+6} \end{aligned}$$



## مثال: تخمین ML و MMSE


MSE مربوط به  $\hat{s}_{ML}$  برابر است با:

$$\begin{aligned} MSE(\hat{s}_{ML}) &= \int_0^\infty \int_0^4 (s - \hat{s}_{ML})^2 f_{s,z}(s, z) ds dz \\ &= \int_0^1 \int_0^4 (s - 4)^2 \frac{1}{12} (s + z) e^{-z} ds dz \\ &\quad + \int_1^\infty \int_0^4 (s - 0)^2 \frac{1}{12} (s + z) e^{-z} ds dz \\ &\approx 4.8636 \end{aligned}$$

$$\hat{s}_{ML} = \begin{cases} 4, & 0 \leq z < 1 \\ 22/9, & z = 1 \\ 0, & z > 1 \end{cases}$$

MSE تخمین MMSE نیز برابر است با:

$$\begin{aligned} MSE(\hat{s}_{MMSE}) &= \int_0^\infty \int_0^4 \left(s - \frac{6z + 16}{3z + 6}\right)^2 \frac{1}{12} (s + z) e^{-z} ds dz \\ &\approx 1.1192 \end{aligned}$$



- تخمین MMSE نسبت به تخمین ML دارای MSE کمتر است.
- تخمین MMSE یعنی  $\hat{s}_{MMSE}$  متفاوت از تخمین ML یعنی  $\hat{s}_{ML}$  است.

## مقایسه معیارهای بهینگی

(ML) تخمین حداکثر احتمال	(MAP) تخمین حداکثر احتمال پسین	
<p>با در نظر داشتن <math>z</math> کدام مقدار <math>s</math> بیشترین احتمال رخداد برای تولید <math>z</math> دارد؟</p>	<p>با در نظر داشتن <math>z</math> کدام مقدار <math>s</math> بیشترین احتمال رخداد را دارد؟</p>	<p>طرح مسئله</p>
<p>حداکثرسازی تابع احتمال <math>f_z(z s=s)</math></p>	<p>حداکثرسازی تابع چگالی احتمال شرطی <math>f_s(s z=z)</math> که بر اساس فرمول بیز معادل با حداکثرسازی <math>f(z s=s)f_s(s)</math> است.</p>	<p>هدف</p>
<p><math>\hat{s}_{ML} =</math> مقداری از <math>s</math> که تابع احتمال <math>f_z(z s=s)</math> را حداکثر سازد. یا به عبارت دیگر برابر است با مقداری از <math>s</math> که به ازای آن رابطه <math>\frac{\partial f_z(z s=s)}{\partial s} = 0</math> برقرار باشد.</p>	<p><math>\hat{s}_{MAP} =</math> مقداری از <math>s</math> که تابع <math>f_s(s z=z)</math> را حداکثر سازد. یا به عبارت دیگر برابر است با مقداری از <math>s</math> که برای آن رابطه <math>\frac{\partial f_s(s z=z)}{\partial s} = 0</math> برقرار است.</p>	<p>تخمین</p>
<p>تابع احتمال <math>f_z(z s=s)</math></p>	<p>چگالی احتمال <math>f_s(s z=z)</math> بر اساس فرمول بیز به آگاهی از <math>s</math> از طریق <math>f_s(s)</math> نیاز است.</p>	<p>اطلاعات مورد نیاز</p>

تخمین حداقل میانگین مربعات خطا

تخمین MMSE خطی

مقایسه روش های تخمین



# مقایسه معیارهای بهینگی

( $MMSE$  تخمین حداقل میانگین مربعات خطا)

خطی  $MMSE$  تخمین

با در نظر داشتن متغیر تصادفی  $z$ ، چه تخمینی از  $s$  به کوچکترین  $MSE$  منجر خواهد شد.

با در نظر داشتن متغیر تصادفی  $z$ ، کدام تابع خطی  $\hat{s} = \lambda z$  به کوچکترین  $MSE$  منجر خواهد شد.

طرح مسئله

معیار  $MSE$  به عبارت دیگر  $E[(s - \hat{s})^2]$  را حداقل کنید.

$\lambda$  را چنان بیابید که  $E[(s - \lambda z)^2]$  را حداقل سازد.

هدف

تخمین

$$\begin{aligned}\hat{s}_{MMSE} &= E[s|z] \\ &= \int_{-\infty}^{\infty} s f_s(s|z) ds\end{aligned}$$

$$\begin{aligned}\hat{s}_{LMMSE} &= \lambda z,\end{aligned}$$

برقرار  $\lambda = E[sz] / E[z^2]$  که در آن رابطه است.

،  $E[sz]$  یعنی  $z$  و  $s$  همبستگی متقابل میان  $E[z^2]$  یعنی  $z$  گشتاور دوم

. فرمول بیز حاکی از آن  $f_s(s|z)$  چگالی  $f_s(s)$  از طریق  $s$  است که به آگاهی از نیاز است.

اطلاعات مورد نیاز

تخمین حداقل میانگین مربعات خطا

تخمین  $MMSE$  خطی

مقایسه روش های تخمین